LMA3NA

Détection du sarcasme dans les tweets arabes

المعنى

Données, architectures, résultats et limites

Omar Elkhali
BDIOT · Travail individuel

TP2 · ArSarcasm-v2
26 octobre 2026

Le contexte peut inverser le sens des mots

يا سلام، الإنترنت انقطع مرة أخرى، خدمة رائعة فعلا

Situation

Une coupure Internet répétée

Formulation

Une louange apparente

Lecture attendue

Une critique ironique

Objectif : distinguer sarcasme et sens littéral malgré les dialectes, le sentiment et le contexte manquant.

Une démarche complète, du corpus à la démonstration

01 Données

Téléchargement officiel, audit et séparation

02 Prétraitement

Nettoyage par famille et conservation des indices

03 Modèles A–E

Baselines, réseaux et modèles préentraînés

04 Évaluation F–G

Test, robustesse, coût et incertitude

05 Application

Comparaison interactive dans LMA3NA

06 Extension

R-Drop ajouté, gain encore à mesurer

Les partitions restent distinctes pendant le protocole

12 548

Tweets du train officiel

Split stratifié à 90/10, graine 42

10 842

Tweets du train nettoyé

Exclusions après split, apprentissage sur ce train uniquement

1 255

Tweets de validation

Choix des modèles, checkpoints et seuils

Le test officiel conserve 3 000 tweets. Les labels test servent à l’évaluation finale, pas au réglage.

L’accuracy masque facilement la classe rare

17,29 %

Sarcasme sur validation

217 exemples positifs parmi 1 255

82,71 %

Accuracy sans détecter un seul sarcasme

Un classifieur toujours négatif obtient pourtant un F1 sarcastique nul

F1 + AP

Métriques retenues

F1 de la classe sarcastique, macro-F1 et Average Precision

Le F1 combine précision et rappel. L’AP résume la courbe précision–rappel sur plusieurs seuils.

Les collisions et contradictions sont traitées avant l’apprentissage

2

Collisions train/test

72

Collisions train/val

331

Lignes dupliquées

47

Groupes contradictoires

Normaliser les clés de comparaison, exclure du train les collisions et les groupes contradictoires, puis dédupliquer le train.

Ces catégories se recouvrent. Leur somme ne correspond pas au nombre de lignes retirées. Val et test restent conservés.

Le nettoyage préserve les marqueurs utiles à l’ironie

Normaliser

Unicode et HTML
Guillemets d’export
Diacritiques et tatweel
Variantes alif et ya

Préserver

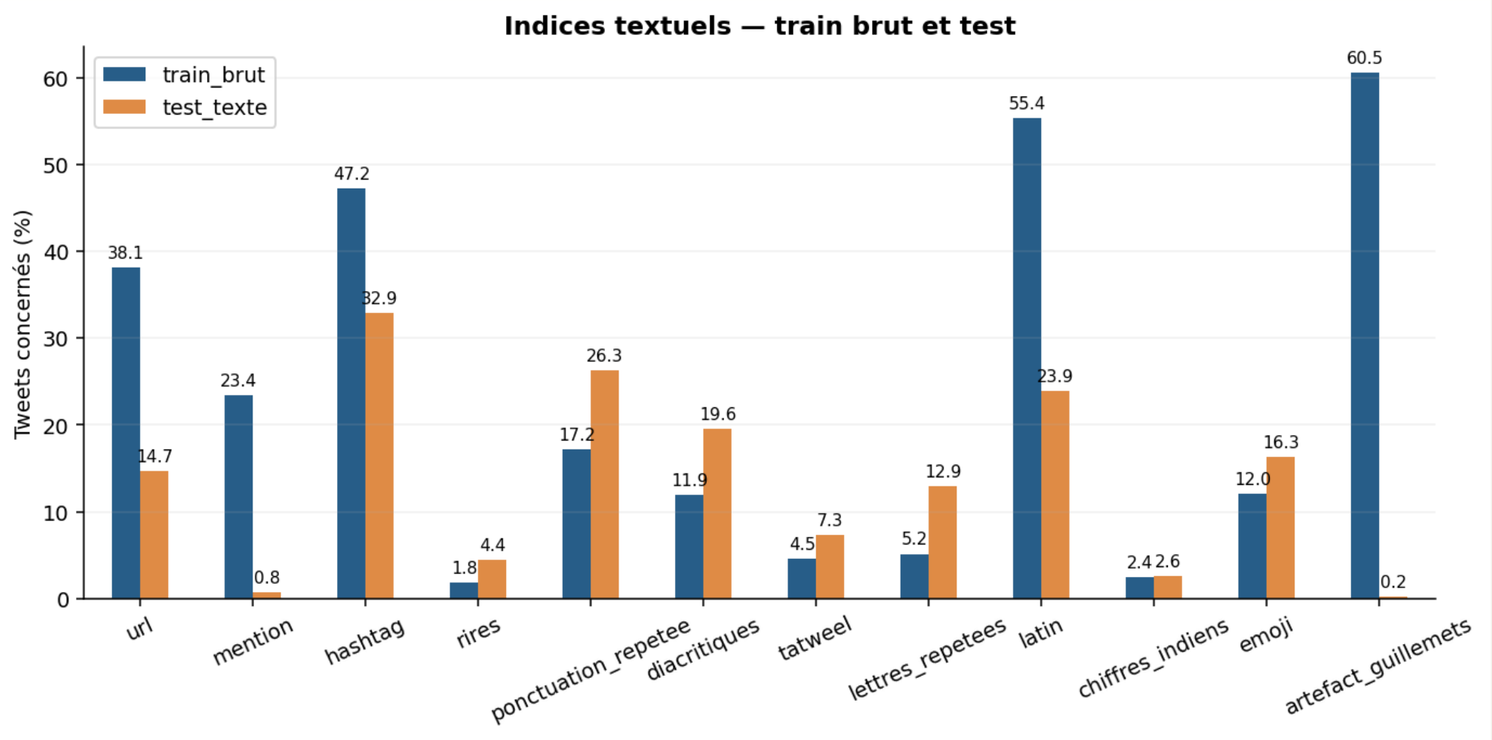
Négations
Emojis et hashtags
Rires et répétitions
Ponctuation expressive

Adapter au modèle

TF-IDF / C : nettoyage conservateur
AraBERT : préprocesseur officiel
MARBERT : nettoyage minimal

Les vocabulaires et statistiques TF-IDF s’ajustent uniquement sur train, après la séparation.

Les indices d’export créent des raccourcis de prédiction

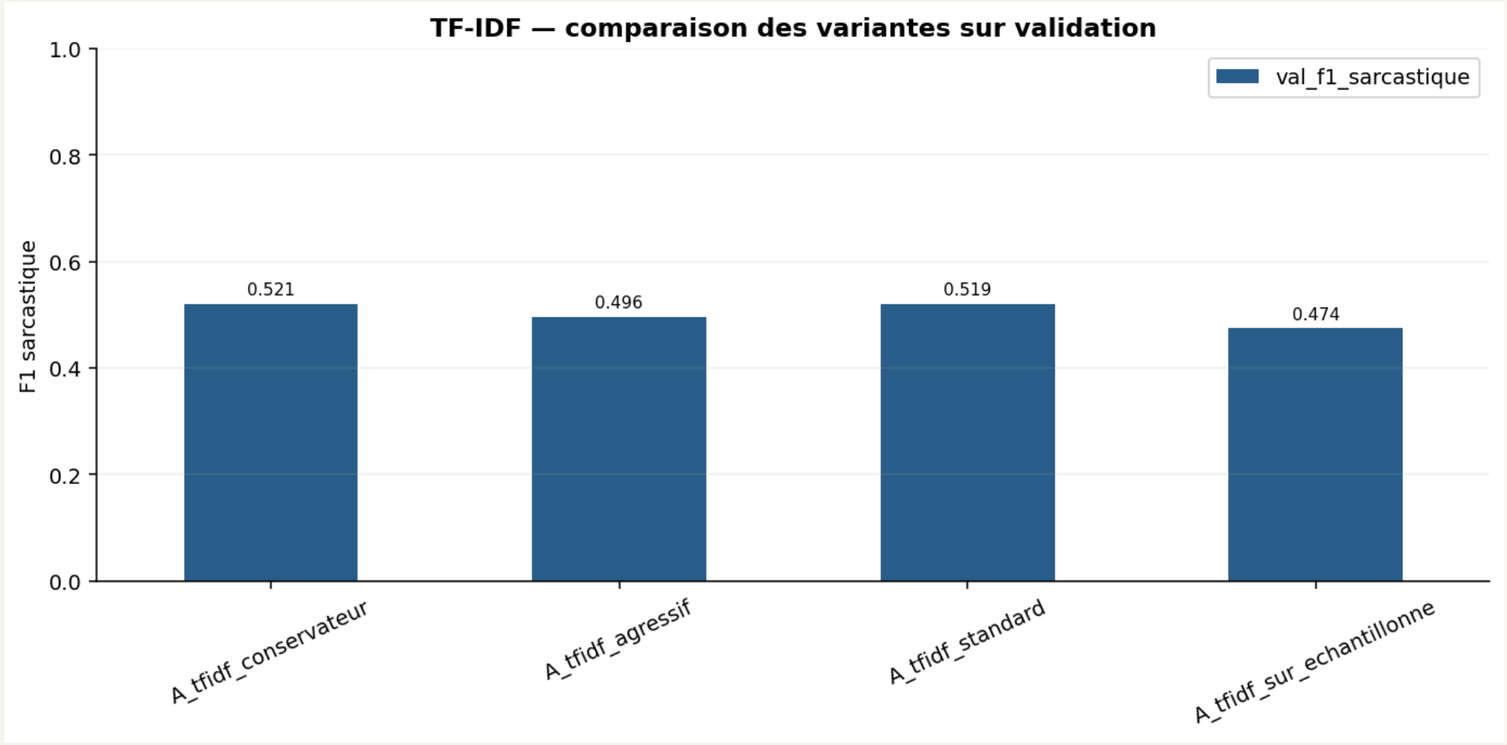


38,09 % contre 14,67 %

Présence d’URL dans le train brut et le test. Les guillemets d’export changent aussi fortement entre les partitions.

Une règle « absence d’URL » atteint un F1 validation de 0,3618 sans résoudre le sens du tweet.

Le nettoyage conservateur gagne la comparaison TF-IDF



F1 val : 0,5206

Mots 1–2 et caractères 2–5, régression logistique et pondération des classes. Le nettoyage agressif descend à 0,4959.

Écart conservateur / agressif : 2,47 points de F1 sur validation, graine 42. Résultat propre à cette comparaison.

Le zero-shot dépend du prompt et du signal de sentiment

Méthode	F1 validation	F1 test
NLI, hypothèses arabes	0,4069	Non retenu en test final
NLI, hypothèses françaises	0,4189	Non retenu en test final
NLI, hypothèses anglaises	0,4224	0,4625
B2, sentiment négatif	0,4695	0,5320

B2 suit l’argmax des trois sentiments. Son score P(négatif) n’est pas une probabilité de sarcasme.

Trois architectures apprennent l’ordre et les relations

C1 · BiLSTM

Embeddings 100D
64 unités par direction
Max-pooling masqué
Classification binaire

C2 · Attention

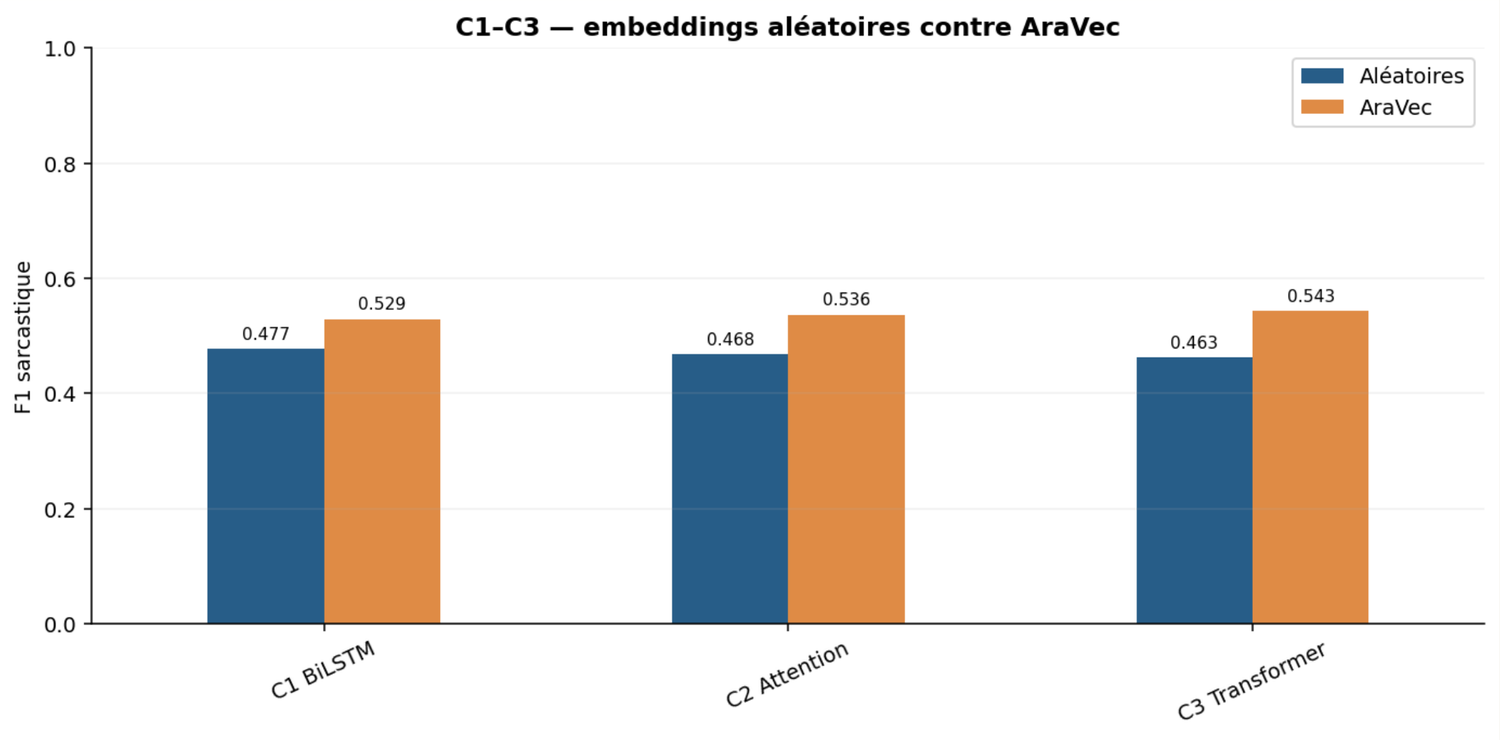
BiLSTM bidirectionnel
Attention apprise
Somme pondérée des états
Classification binaire

C3 · Transformer

Projection 128D
2 couches, 4 têtes
Positions sinusoïdales
Masque du padding

Budget : au plus 8 époques, patience 2. Le dialecte n’est pas fourni comme entrée du classifieur.

AraVec améliore les trois réseaux statiques

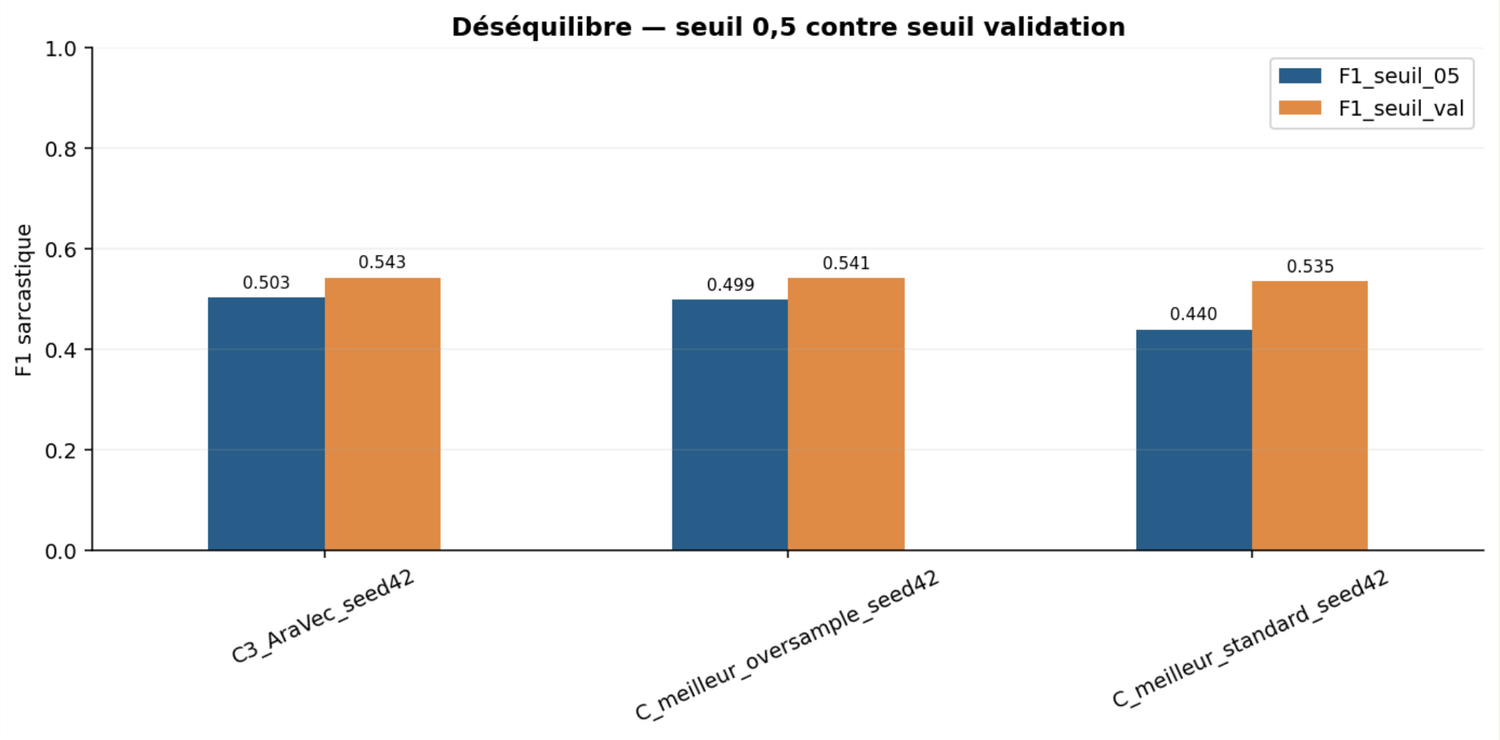


C3 : 0,4627 à 0,5427

AraVec Twitter 100D apporte une représentation préalable. C3 AraVec devient le meilleur réseau statique sur validation.

Embeddings figés pendant deux époques puis dégel possible. Le meilleur checkpoint peut précéder le dégel.

Le seuil compte autant que le traitement du déséquilibre



+3,95 points de F1

Pour C3 AraVec, le seuil de validation porte le F1 de 0,5032 à 0,5427. Pondération et sur-échantillonnage restent proches sur ce run.

Le sur-échantillonnage intervient uniquement après le split. Le test ne sert jamais à choisir le seuil déployable.

AraBERT gelé fournit des représentations contextuelles

Tweet

Prétraitement officiel

AraBERT gelé

Représentations des tokens

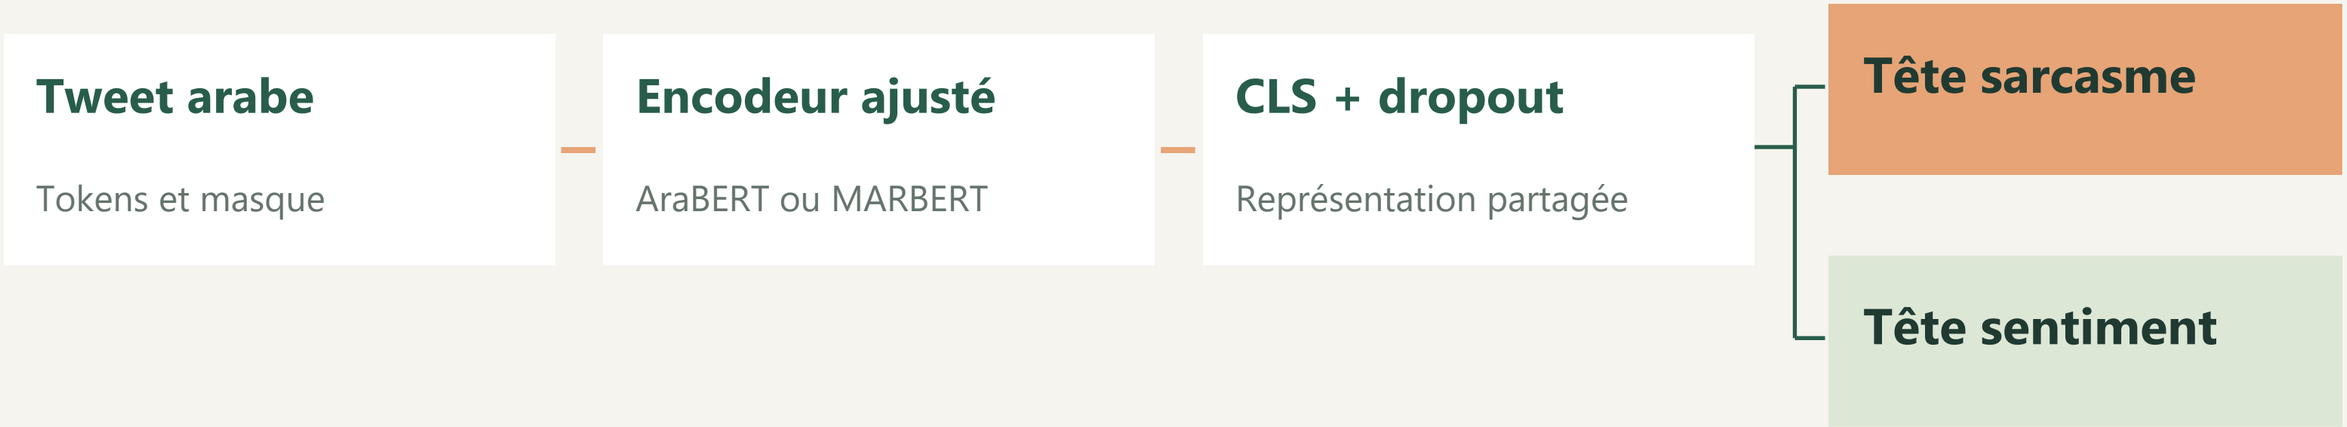
Tête entraînée

CLS, moyenne ou BiLSTM

Tête	F1 validation	Temps tête
CLS + régression logistique	0,6054	4,7 s
Moyenne masquée + régression	0,6316	7,3 s
BiLSTM + attention	0,6625	12,7 s

Ces temps excluent l’extraction des représentations et le chargement. L’encodeur reste nécessaire à l’inférence.

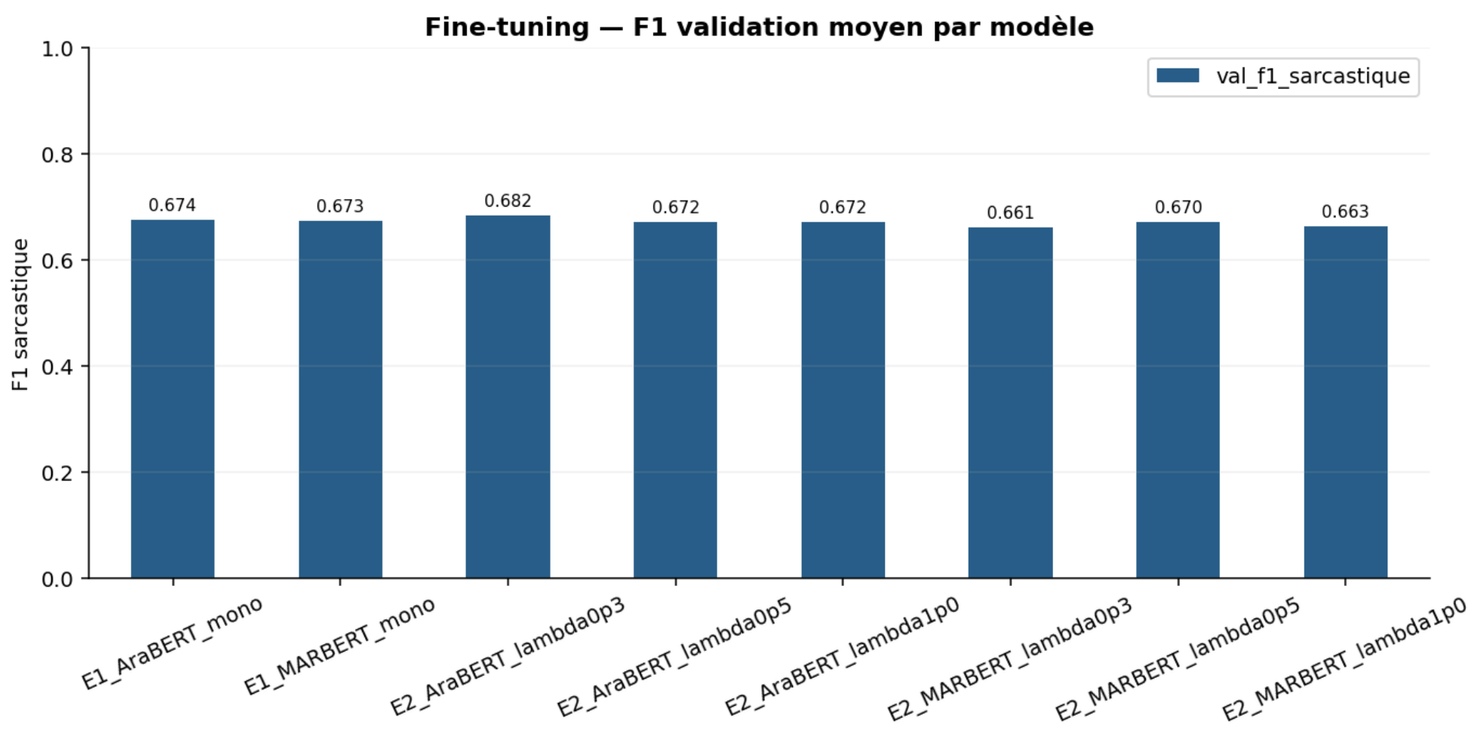
Le multi-tâche partage l’encodeur entre sarcasme et sentiment



E1 : perte sarcasme pondérée
E2 : perte sarcasme pondérée + λ × perte sentiment

E1 utilise une tête. E2 utilise deux têtes linéaires. Le signal auxiliaire peut aussi produire un transfert négatif.

La validation sélectionne AraBERT E2 avec λ = 0,3

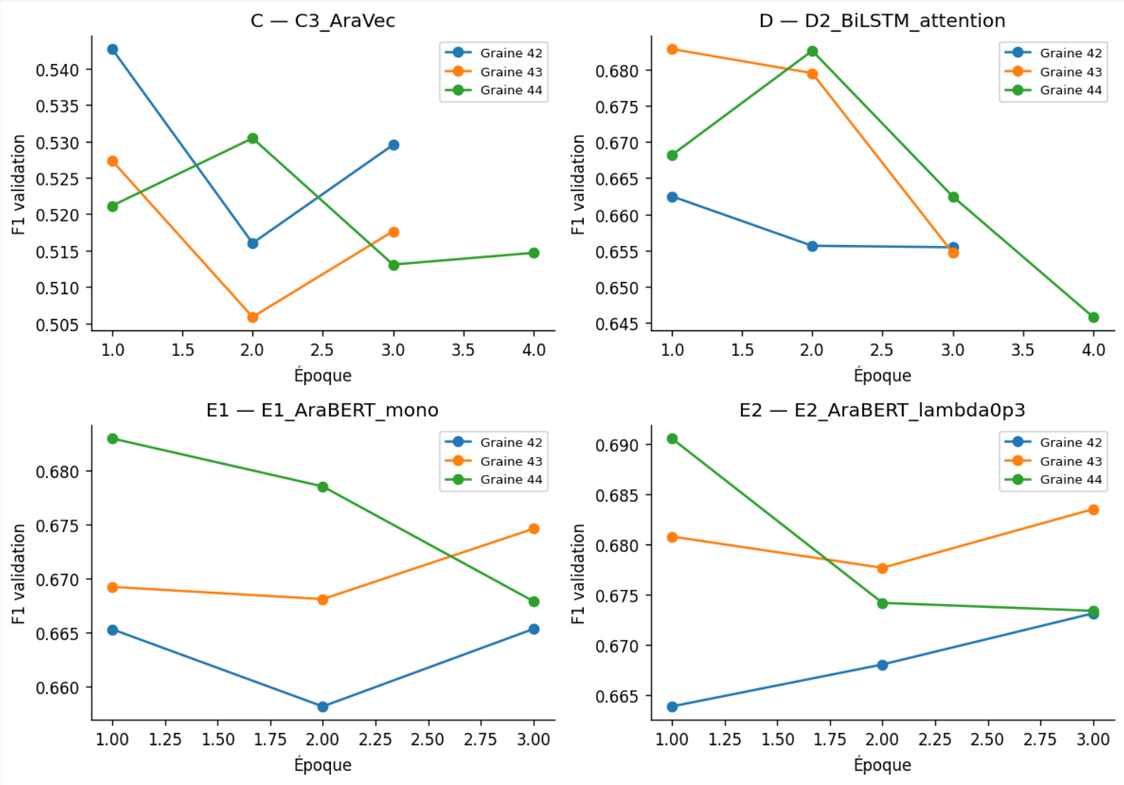


0,6824 de F1 moyen

AraBERT E2 dépasse E1 sur validation. MARBERT reste proche en mono-tâche, mais son multi-tâche ne gagne pas cette comparaison.

λ = 0,3 / 0,5 / 1 à graine 42. Puis répétition de E1 et du λ retenu aux graines 43 et 44 pour chaque encodeur.

Les checkpoints reposent sur les courbes de validation

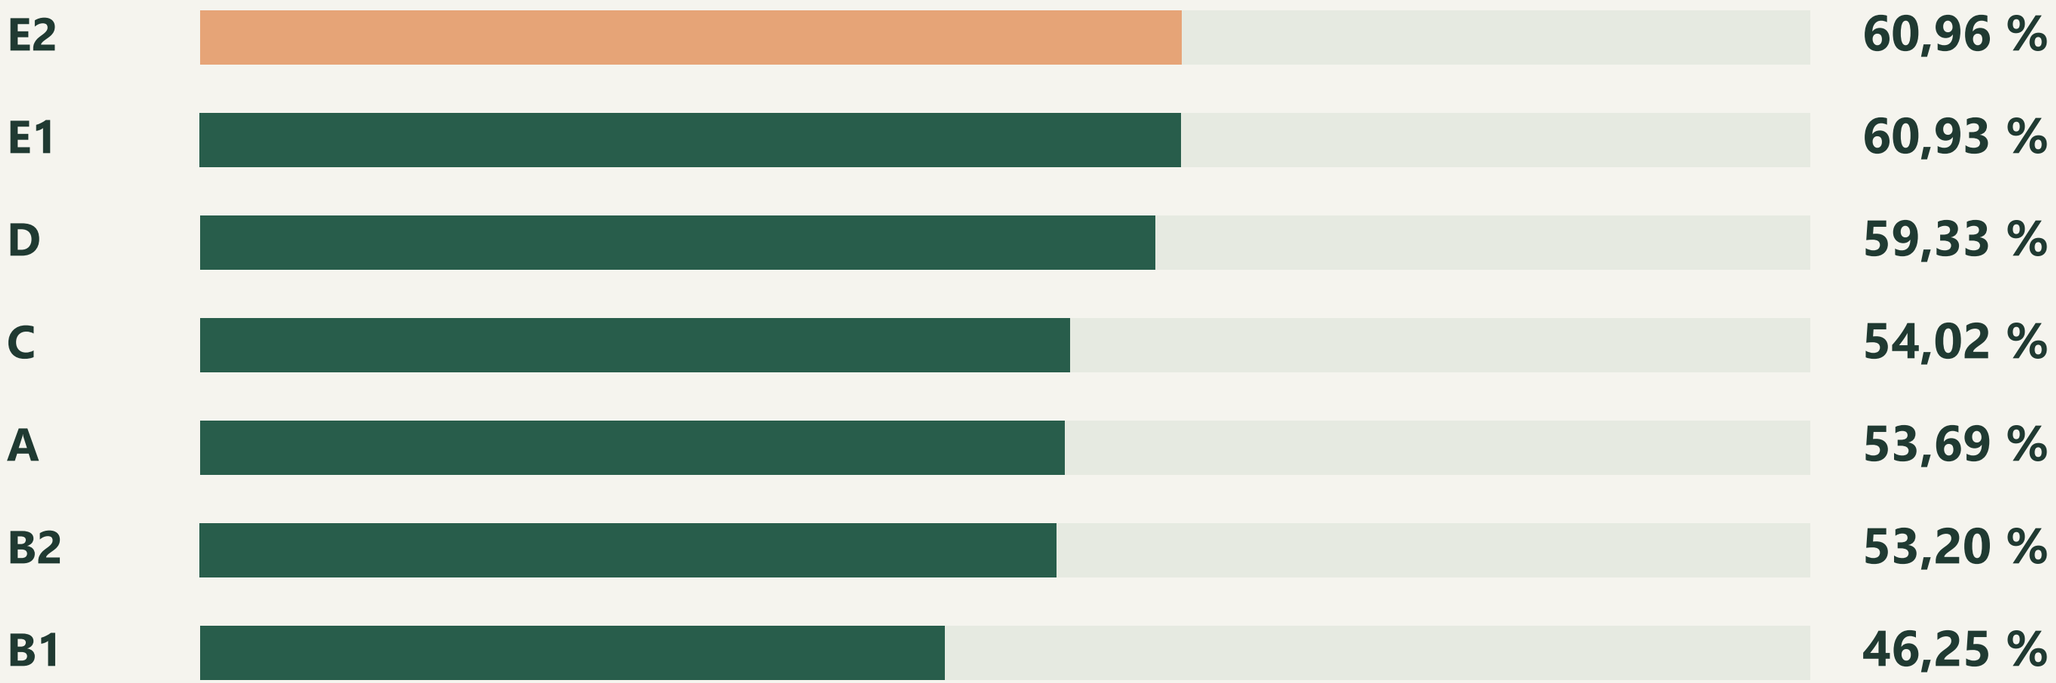


Réglages mesurés

AdamW, LR 2e−5
Weight decay 0,01
Warmup 10 %
Batch 32, AMP FP16
PLM : 3 époques max.
Patience 2, longueur 64

Le meilleur checkpoint précède parfois la dernière époque. Les sorties historiques ne sont pas des résultats à cinq époques.

E1 et E2 obtiennent presque le même F1 test moyen



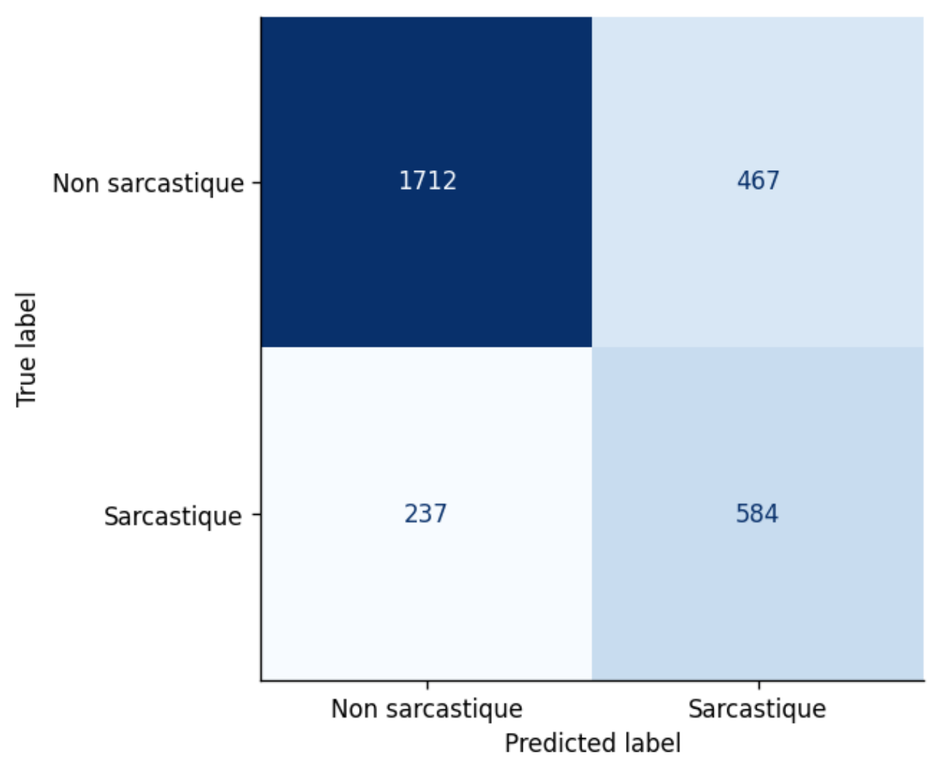
E2 : 0,6096 ± 0,0131 ; E1 : 0,6093 ± 0,0221. Cet écart ne démontre pas un gain net du multi-tâche.

Les trois graines rendent la variabilité visible

Modèle	Graine	F1 sarcastique	Macro-F1	AP
A · TF-IDF	42	0,5369	0,6702	0,5349
A · TF-IDF	43	0,5369	0,6702	0,5349
A · TF-IDF	44	0,5369	0,6702	0,5349
C · AraVec	42	0,5448	0,6723	0,5428
C · AraVec	43	0,5446	0,6762	0,5418
C · AraVec	44	0,5312	0,6825	0,5548
D · BiLSTM-attention	42	0,5962	0,7162	0,6293
D · BiLSTM-attention	43	0,6037	0,7218	0,6251
D · BiLSTM-attention	44	0,5799	0,7152	0,6217
E1 · AraBERT	42	0,6248	0,7300	0,6315
E1 · AraBERT	43	0,5839	0,7192	0,6532
E1 · AraBERT	44	0,6191	0,7228	0,6465
E2 · AraBERT λ 0,3	42	0,6239	0,7267	0,6355
E2 · AraBERT λ 0,3	43	0,5984	0,7255	0,6554
E2 · AraBERT λ 0,3	44	0,6065	0,7178	0,6446
B1 · NLI anglais	42	0,4625	0,5817	0,4077
B2 · Sentiment	42	0,5320	0,6114	0,4928

17 évaluations : A/C/D/E sur trois graines, B1/B2 sur un passage. Les métriques proviennent des tableaux sauvegardés.

La matrice révèle encore 237 sarcasmes manqués

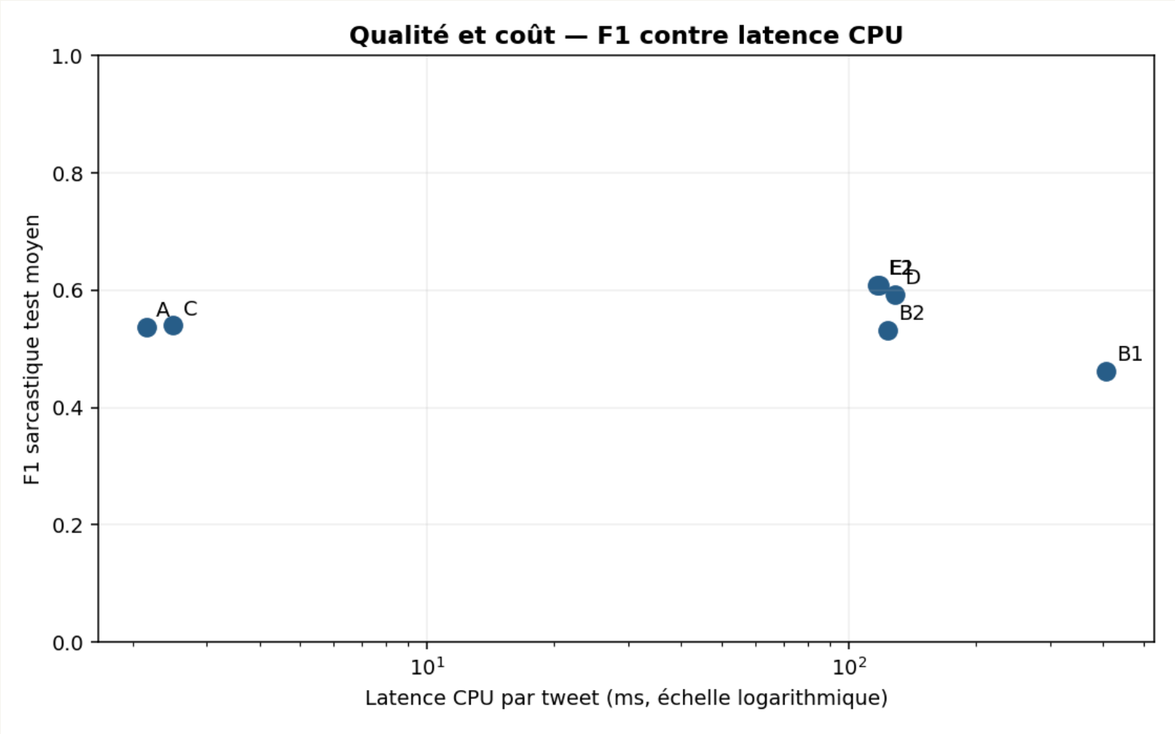


E2 AraBERT · graine 42

Seuil validation : 0,490785
584 vrais positifs
467 faux positifs
237 faux négatifs
1 712 vrais négatifs

Précision 0,5557 ; rappel 0,7113 ; F1 0,6239. Ce run individuel diffère de la moyenne sur trois graines.

TF-IDF reste un compromis intéressant sur CPU



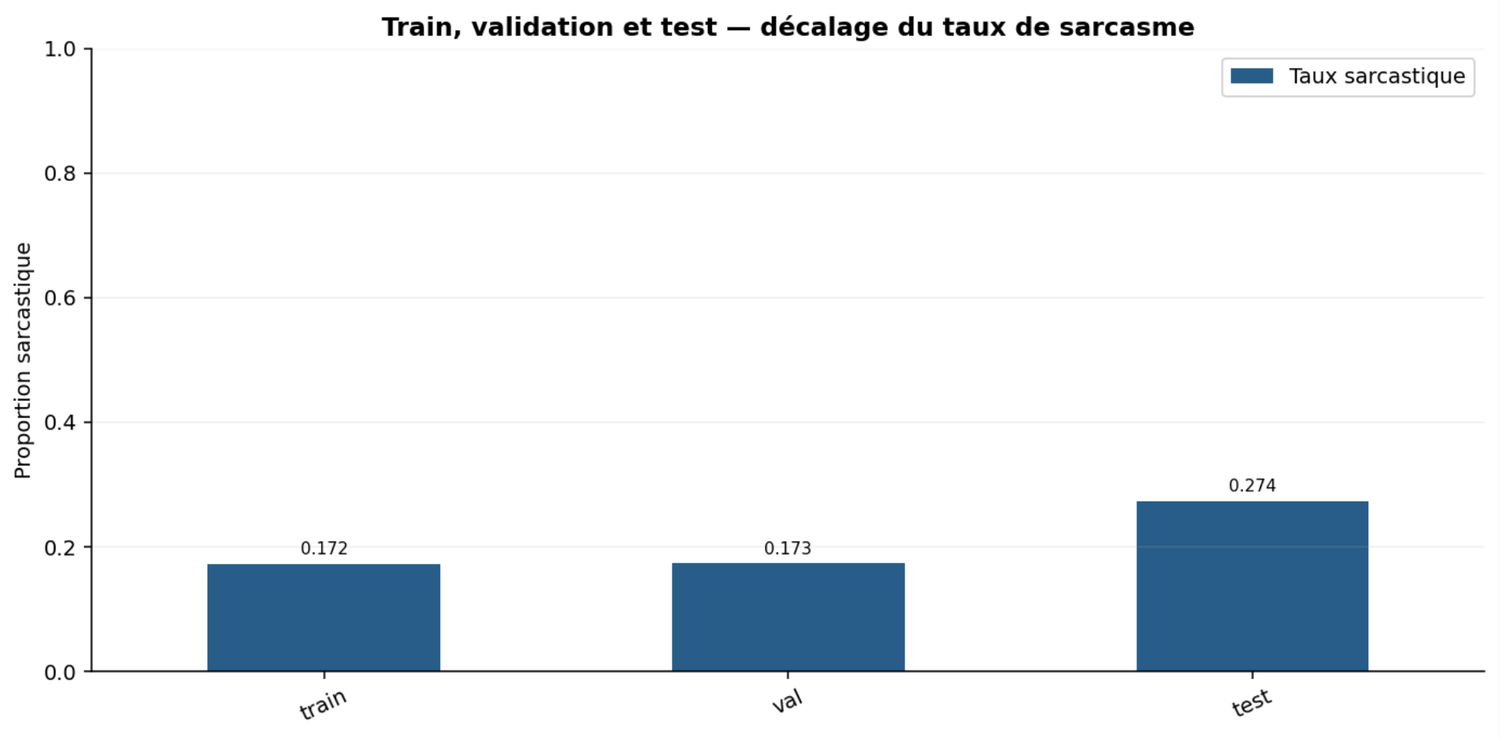
2,15 ms contre 116,63 ms

TF-IDF : F1 0,5369
Poids 5,84 Mo

E2 : F1 0,6096
Poids 540,88 Mo

Latence historique sur CPU Colab, batch 1 après chauffe. Ces valeurs ne décrivent pas le Ryzen local ni un service en charge.

Le taux de sarcasme change entre validation et test



+10,08 points

Le prior passe de 17,29 % sur validation à 27,37 % sur test. Les dialectes, thèmes et indices de surface changent également.

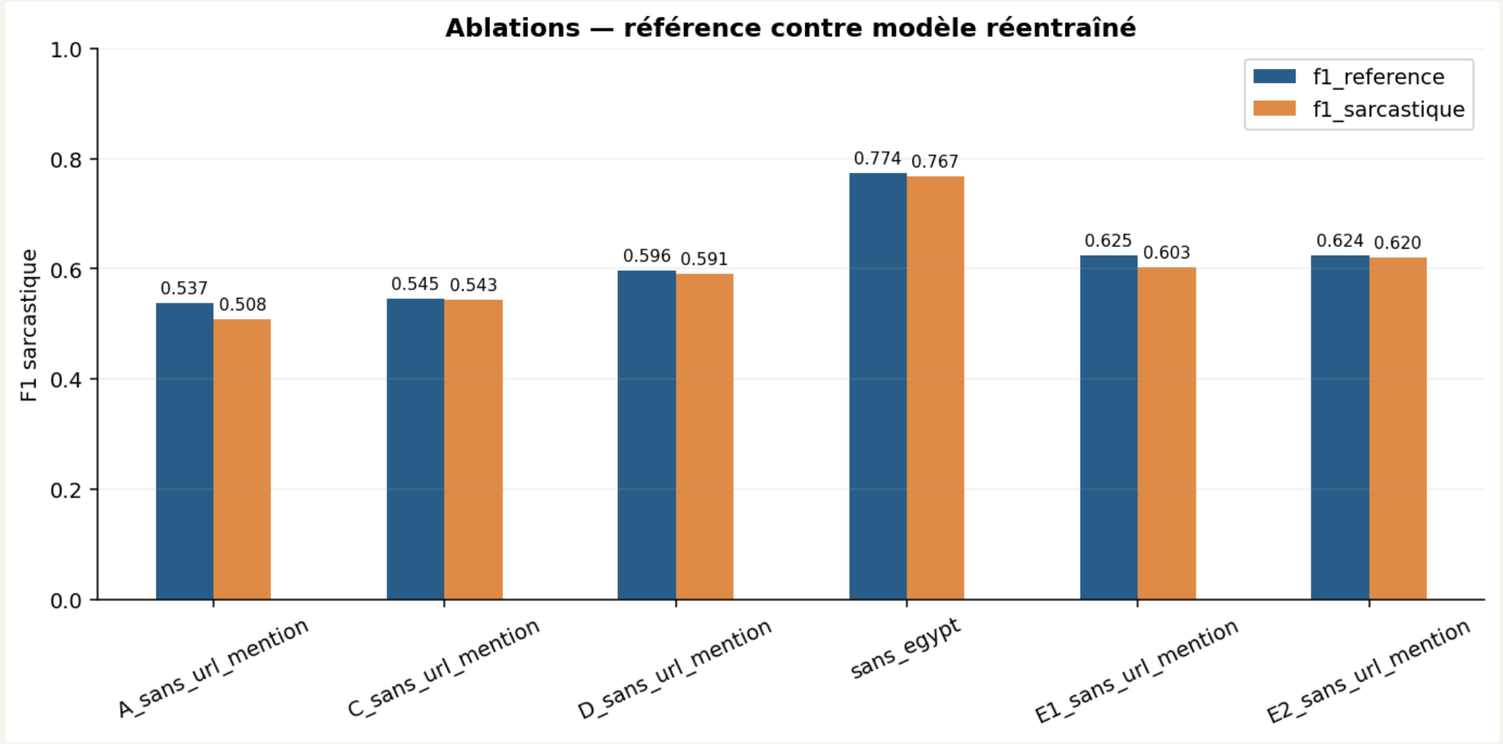
Les seuils optimisés a posteriori sur test servent au diagnostic. Ils ne deviennent pas des seuils déployables.

Les sous-groupes URL ont des distributions différentes

Famille	F1 sans URL	F1 avec URL
A	0,5437	0,0769
C	0,5591	0,1538
D	0,6035	0,1935
E1	0,6318	0,2424
E2	0,6301	0,2581

Avec URL : 16 positifs / 440 tweets. Sans URL : 805 / 2 560. Ce contraste ne mesure pas un effet causal isolé des URL.

Retirer les indices ne garantit pas de meilleurs résultats



E2 sans liens : 0,6199

La référence E2 graine 42 obtient 0,6239. Le réentraînement sans URL et mentions ne montre pas de gain dans cette expérience.

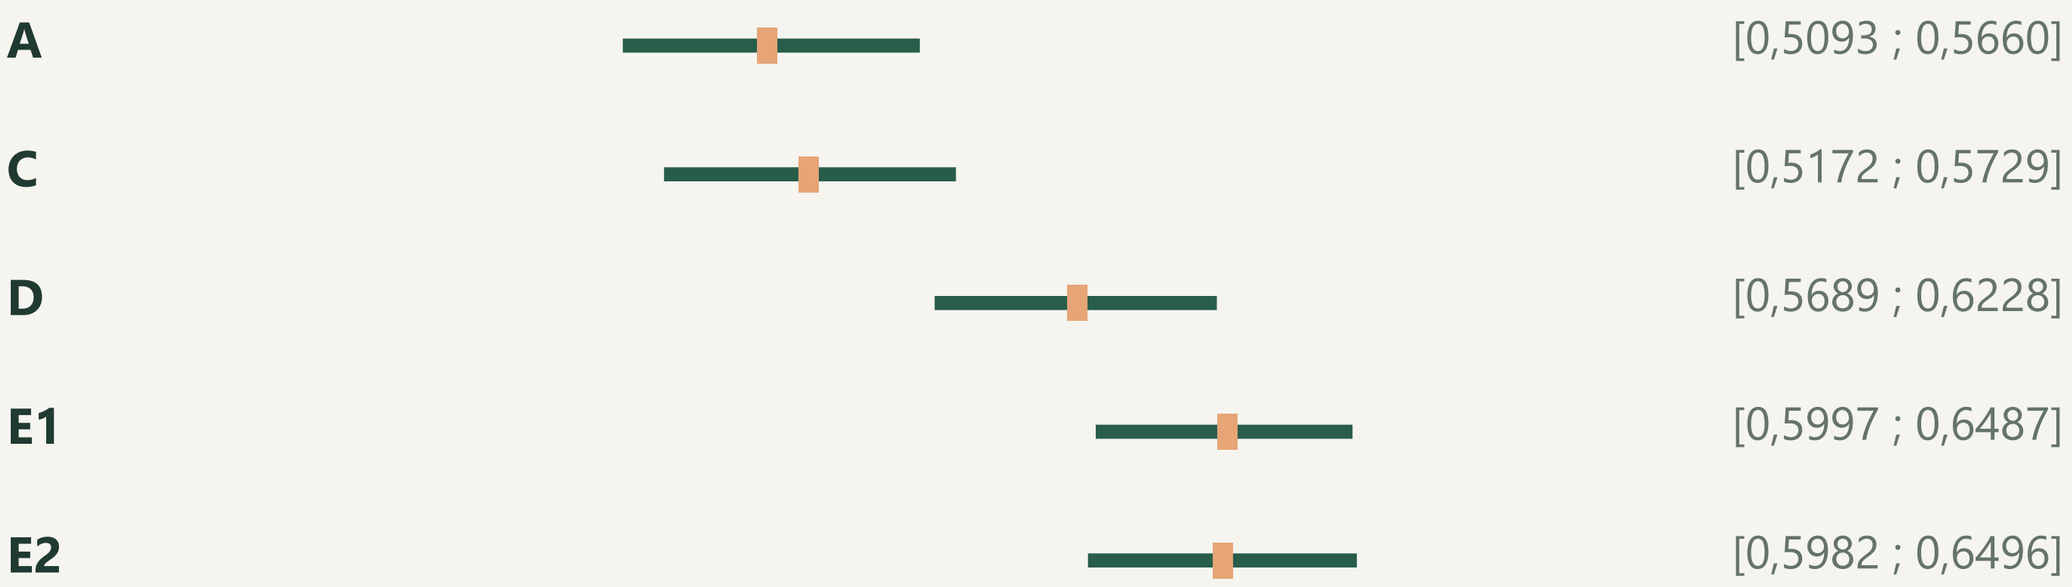
Sans égyptien : 8 522 tweets train. E2 sur les 306 tweets égyptiens test passe de 0,7736 à 0,7674.

Les dialectes rares limitent les conclusions de déploiement

Dialecte	Train nettoyé	Validation	Test
Égyptien	2 320	260	306
Golfe	511	68	322
Levantin	549	55	47
Maghrébin	35	5	2
Arabe standard	7 427	867	2 323

Les deux tweets maghrébins du test sont négatifs. Ils ne permettent pas d’établir une fiabilité sur la darija.

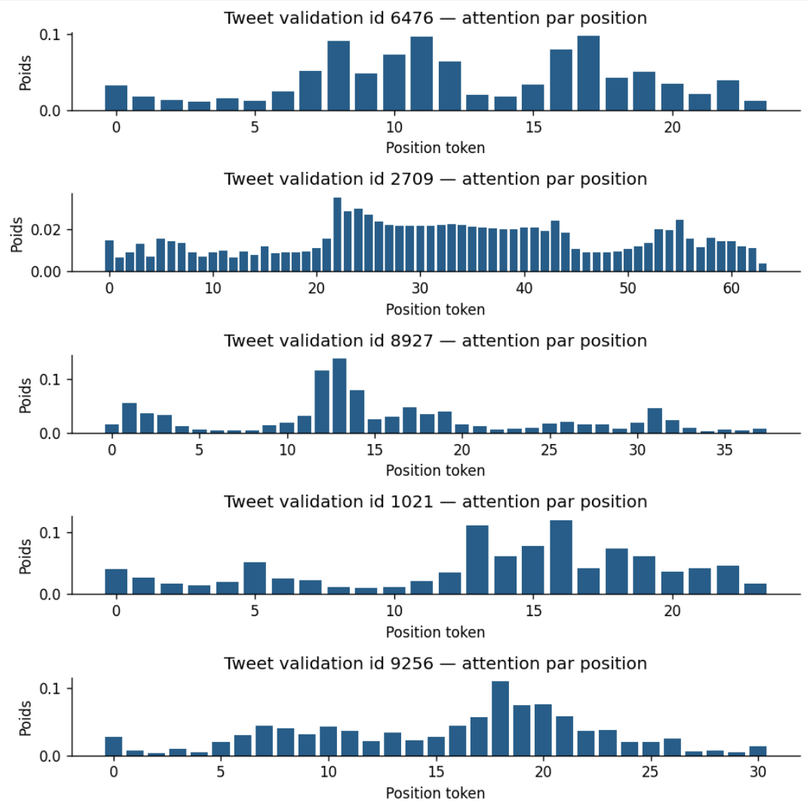
Les intervalles et les désaccords nuancent le classement



Axe F1 agrandi : 0,45 à 0,70. Bootstrap 1 000 réplications, IC à 95 %, graine 42.

McNemar exact E2 / D2 : 151 contre 156 erreurs gagnées, p = 0,8195. Ce test ne compare pas directement les F1.

L’attention indique des poids, sans prouver la compréhension



Cinq tweets de validation

La tête D2 pondère les représentations des tokens. Des mots de contenu et de la ponctuation reçoivent de l’attention.

Un poids élevé n’est pas une explication causale de la décision.

Lecture qualitative à rapprocher du texte arabe, de la prédiction et des erreurs. Aucun score supplémentaire ne résulte de cette figure.

L’analyse des erreurs demande encore une relecture humaine

15 + 15

Faux négatifs et faux positifs

Échantillon d’erreurs à analyser dans leur contexte

19 / 30

Contexte ou ironie implicite

Catégorie proposée automatiquement, encore provisoire

6 + 5

Dialecte / marqueur

6 cas dialecte–contexte et 5 marqueurs potentiellement mal interprétés

Ces catégories ne sont pas une annotation humaine finalisée. Aucun taux global de bruit ne peut en être déduit.

Les phrases réelles exposent une limite visible du modèle

Phrase résumée	Lecture attendue	Score	Décision
Internet coupé, « service excellent »	Ironie	0,002247	Non sarcastique
Beau temps, promenade	Littéral	0,001082	Non sarcastique
Deux heures de retard, « merci »	Ironie	0,015058	Non sarcastique
Je n’ai pas aimé ce film	Critique littérale	0,017326	Non sarcastique

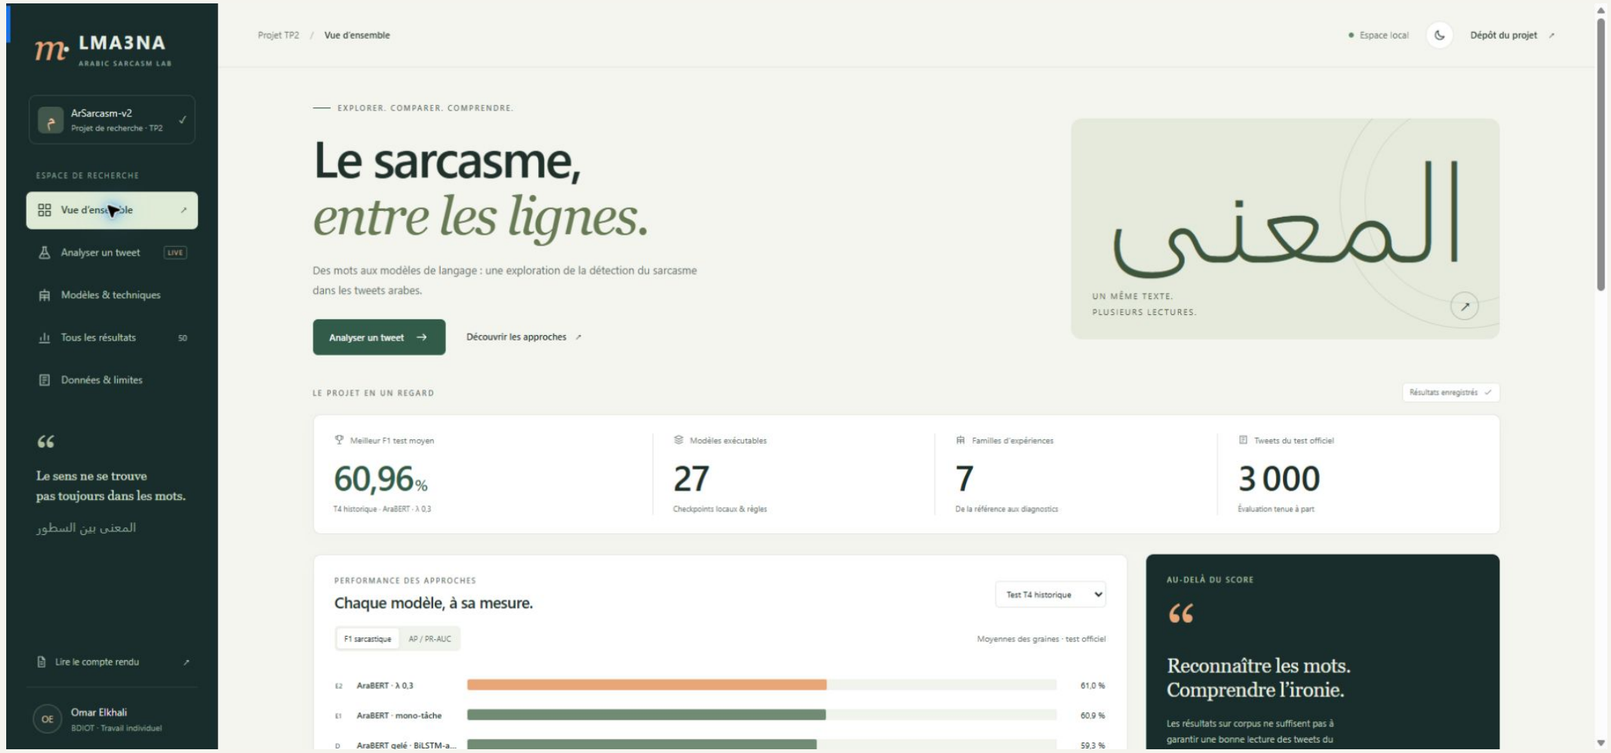
Capture : E2 λ 0,5, seuil 0,579043. Checkpoint différent du final T4. Quatre exemples ne forment pas un nouveau test annoté.

Les difficultés techniques ont des solutions identifiées

Problème	Solution dans le projet
Dépendances absentes sur Colab	Installation dans le Python du noyau, puis redémarrage
Disque Windows invisible depuis Colab	Chemins du projet distant et ressources vérifiées
Chargements et tokenisations répétés	Caches, padding dynamique et réemploi des ressources
Avertissement bert.pooler	CLS brut utilisé, pooler hors de la tête de décision
Graphiques historiques vides	Affichage conditionnel des données, exclusion des axes vides
CPU local, RAM 16 Go	Inférences séquentielles et chargement différé

Le cache de taille de vocabulaire évite aussi un calcul répété dans la préparation de la campagne T4.

LMA3NA rassemble les résultats et leurs sources

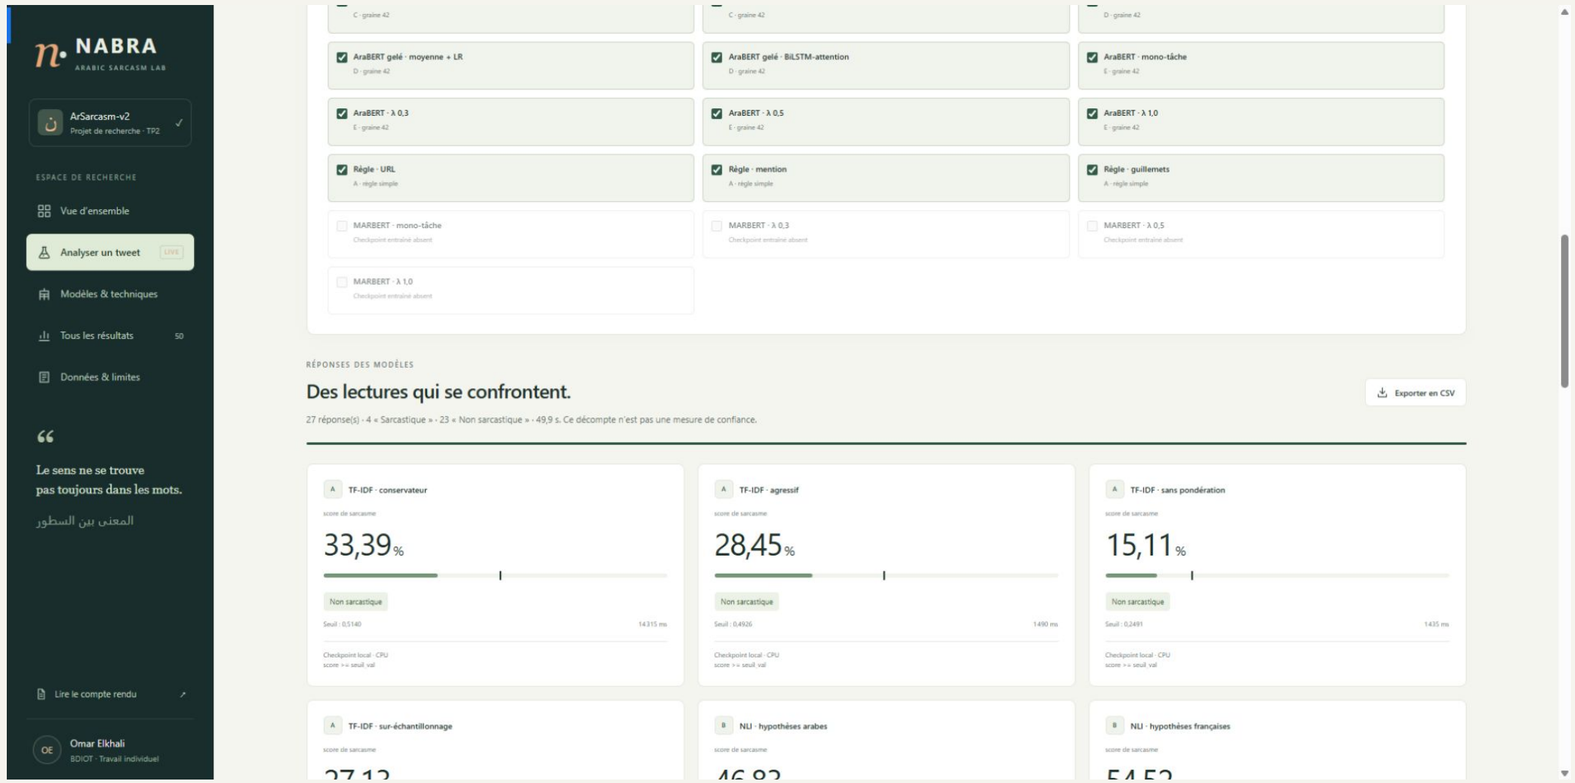


Un espace de restitution

50 tableaux enregistrés
19 figures exploitables
17 évaluations T4
Modèles et techniques
Provenance et limites

Application locale. Les métriques T4 historiques et la validation CPU locale restent séparées.

La saisie compare les checkpoints disponibles localement



Capture technique historique, avant le renommage de Nabra en LMA3NA

27 réponses réelles

24 modèles et 3 règles
Scores, seuils et décisions
Export CSV
4 variantes MARBERT sans poids locaux

Les poids T4 historiques ne sont pas tous présents ici. Le test technique de 27 réponses valide le fonctionnement, pas la qualité scientifique.

R-Drop ajoute une contrainte de cohérence entre deux passages

Même tweet

Aucune donnée supplémentaire

Deux passages

Dropout différent à chaque fois

Deux distributions

p_1 et p_2 sur le sarcasme

Perte = CE moyenne + λ × CE sentiment moyenne + α × KL symétrique des prédictions de sarcasme

Pendant l'entraînement seulement. À l'inférence : un passage en mode eval(). Gain encore à mesurer sur ce projet.

L’extension R-Drop dispose d’un protocole sans résultat annoncé

Comparaison appariée

E2 AraBERT, λ 0,3
Référence : α = 0
R-Drop : α = 1
Graines 42, 43, 44

Réglages identiques

Même train et validation
LR 2e−5, longueur 64
Batch effectif 32
3 époques max., patience 2

État vérifié

3 cellules ajoutées
Exécution désactivée
Aucun run local terminé
Aucun gain revendiqué

Six runs au total. Sélection sur validation. Les résultats seront séparés des expériences historiques A–G.

Les prochaines étapes privilégient des comparaisons contrôlées

Priorité	Action	Critère de décision
1	Revalider checkpoint, prétraitement et seuil	Même chaîne en évaluation et en saisie
2	Exécuter référence / R-Drop	Écarts appariés sur trois graines
3	Comparer LR, longueur et prétraitement	Gain validation et coût mesuré
4	Étudier ensemble ou TAPT sur train	Extension isolée, sans labels test
5	Finaliser les preuves et l’analyse	Exports test et relecture des erreurs

Pas de modification des réglages pour réussir quelques phrases de démonstration. Aucune amélioration n’est garantie avant mesure.

La reproductibilité dépend aussi des artefacts conservés

Disponible

Code et notebooks
Tableaux T4 exportés
Figures historiques
Registre et checkpoints CPU

À compléter

17 CSV individuels test
Poids T4 nécessaires au service
Relecture des 30 erreurs
Résultats R-Drop exécutés

Séparations explicites

CPU / T4
Validation / test
Agrégats / prédictions
Exécuté / seulement ajouté

Le dépôt public permet de consulter le projet : github.com/OmarElkhali/TP2-ArSarcasm-v2

Bilan du projet

0,6096

Meilleur F1 test moyen enregistré
E2 AraBERT, λ = 0,3

Les expériences couvrent les familles A–G.
Les essais réels montrent encore des sarcasmes manqués.
R-Drop fournit une prochaine comparaison mesurable.

Sources scientifiques et preuves du projet

ArSarcasm-v2

iabufarha/ArSarcasm-v2, jeu officiel et partitions

https://github.com/iabufarha/ArSarcasm-v2

AraBERT

Antoun, Baly et Hajj, 2020

https://aclanthology.org/2020.osact-1.2/

ARBERT & MARBERT

Abdul-Mageed, Elmadany et Nagoudi, 2021

https://aclanthology.org/2021.acl-long.551/

R-Drop

Liang et al., NeurIPS 2021

https://proceedings.neurips.cc/paper_files/paper/2021/hash/5a66b9200f29ac3fa0ae244cc2a51b39-Abstract.html

Mesures : results/report_data/*.csv et figures du notebook. Détails de provenance et notes orales inclus dans le PowerPoint.